6.MapReduce

学生: 张帅豪 18030100101 老师: 李龙海

分布式并行计算平台

分布式计算平台(或叫框架)和运行在平台之上的应用层模块相互协作完成一个完整的分布式计算任务。

分布式计算平台的作用:

- 1. 将输入数据进行分片,将每个分片交给一个计算子任务处理;
- 2. 将不同的计算子任务分发给不同的计算节点执行;
- 3. 子任务分发时将考虑如下因素:各个计算节点的当前负载;尽量让计算子任务和对应的数据分片处于同一台物理主机。
- 4. 帮助实现中间计算结果的合并、中间结果在不同计算节点之间的交换(混洗);
- 5. 容错性: 监视各个子任务的执行状态, 将执行失败的子任务重新调度给其它节点执行。
- 6. 可扩展性:对集群中计算节点的增长或减少可以自适应

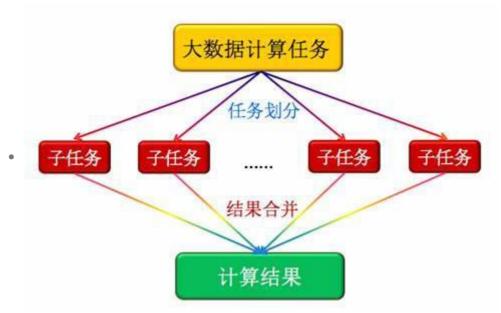
应用层模块的作用:

专注于实现框架要求下和具体应用层逻辑相关的子任务计算逻辑。

MapReduce

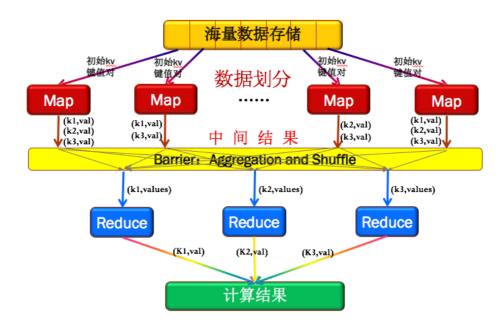
宏观思想:

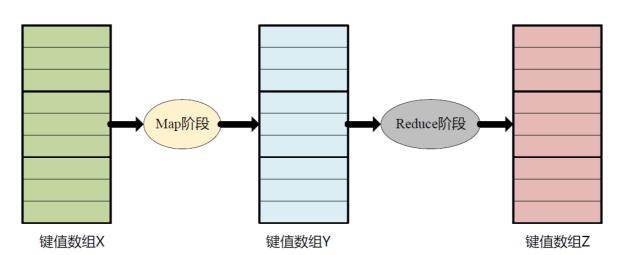
- 将面向大数据的计算任务划分多个子任务,将输入文件划分成数量相等的多个分片。每个子任务处理一个分片。
- 不同的子任务在不同的计算节点上运行。
- 最后将各个子任务的中间结果合并, 计算出最终结果。



mapreduce并行计算模型

• 将大数据并行计算任务划分为三个阶段: Map阶段、聚集混洗阶段(含二次分区), Reduce阶段。MapReduce并行计算模





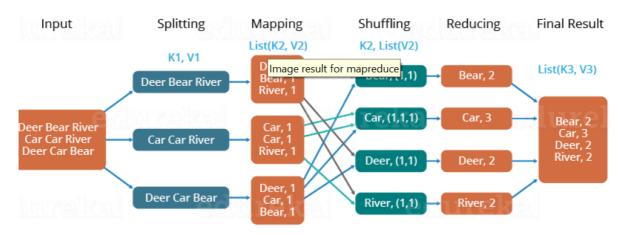
- 三个键值数组X、Y、Z的Key的类型和Value的类型不一定相同;
- 键值数组X经过Map转化成了键值数组Y,X和Y之间可以是一对一、一 对多和多对一的关系。
- 键值数组Y再经过Reduce转化成了键值数组Z,Y和Z之间可以是一对一、 一对多和多对一的关系。

Map reduce 算法梗概

- Map 阶段:第一阶段并行,将输入文件划分成多个分区,每个分区都交给一个独立的 Map 子任务 进行
 - 处理。强制要求每个 Map 子任务将输出规整为一系列 <key, value>对的形式。
- 聚集混洗阶段:并不同 Map 子任务输出的 <key, value>数组按照 key 进行聚集,聚集成数组 A = {<k1,
 - [v1, v2, ...]>, <k2, [v3, v4, ...]>, <k3, [v5, v6, ...]>, 的形式。(按 key 排序)
- Reduce 阶段: 第二阶段并行,将聚集之后的数组 A 划分成多个分区,每个分区都交给一个独立的 Reduce
 - 子任务进行处理。 Reduce 子任务也将输出规整为一系列 <key,value> 对的形式。
- 如果 Reduce 阶段输出不是最终结果,还可以启动新一轮 MapReduce 过程。

The Overall MapReduce Word Count Process

edureka!



在网页数据库中统计不同网页被引用的频率。

map函数处理网页请求的日志文件,并输出 <URL, 1> 的键值对。 reduce 函数把相同 URL 访问次数值相

加到一起,输出 <URL,总访问数的键值对。

根据网页数据库生成关于每个网页的逆向链接统计。

map函数把 source 网页中每一个链接到 target URL 的结果输出为 <target, 。 reduce 函数把所有和给定 target 相关的 source URLs 连接起来,并且输出 <target, list(。举个例子,搜索引擎中输入关键字,网络爬虫就会根据关键字(查 找相关的网页并找到所有的链接,这些就是 list(source)。

更多应用

- 生成关于网页数据库的全文检索索引(倒排索引)。
- 海量数据的全文查找或关键字匹配
- 数据过滤
- 数据去重
- 数值数组计算总和、平均值、最大最小值、TopN
- 计算数字图像直方图
- 海量数据的随机采样
- 给出child-parent数据表,要求输出grandchild-grandparent数据集表